CASE REDUÇÃO DE CPU

Análise de Paralelismo para Redução de CPU

RESUMO

Olá, sou DBA SQL Server Sênior, atuando com SQL há 10 anos. Criando documentações com ênfase em melhorias baseadas nos meu Cases.

Junior Moraes

SQL Server DBA Senior Consultant

Início da Análise.

Ao longo dos dias um ambiente consideravelmente robusto composto por 64 CPU, divididos em 2 Sockets, estava enfrentando momentos de crises rotineiramente em diversos horários do dia.

O que colocou uma pulga na orelha dos DBA's de porque estava ocorrendo tal situação.

Poderia ficar aqui explicando e mostrando outros causadores desse desvio de consumo, mas vamos direto ao foco que é mostrar o impacto da configuração de "Cost Threshold for Paralelismo" ou CTFP, pode causar no seu ambiente se mau dimensionado.

Logo de cara um Histórico de consumo de CPU desse ambiente nos últimos 30 dias.

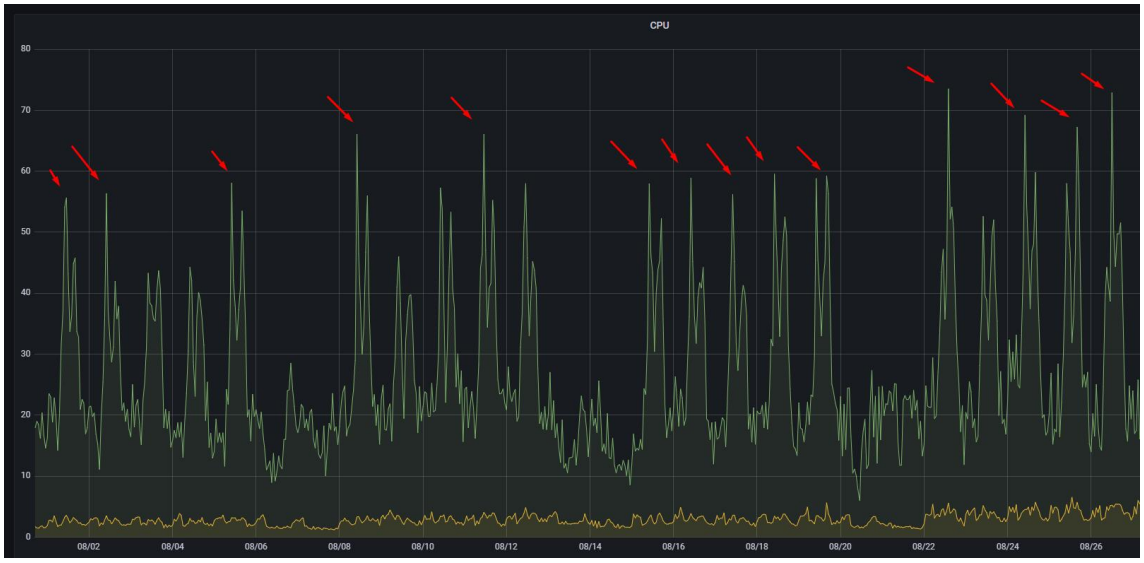

Percebam que durante o expediente o consumo de CPU ficava na maior parte acima de 80% de consumo.

O que por diversas vezes ocasionava *Locks* e *DeadLocks* por falta de threads. Afetando diretamente as aplicações que utilizam esse servidor.

Iniciando uma busca do que estava acontecendo no ambiente, procurei os principais **WAITS TYPE** do SQL Server, para analisar se existia algum entre os tops que poderia estar relacionado a CPU.

E aqui tivemos o primeiro êxito.

No momento da coleta, tínhamos o **CXPACKET como TOP 1 Wait** do ambiente.

Waits este que está diretamente relacionado a CPU e Paralelismo no SQL Server, e que já nos ajuda a farejar as possíveis causas do consumo desenfreado.

	WaitType	Wait_S	Resource_S	Signal_S	WaitCount	Percentage	AvgWait_S	AvgRes_S	AvgSig_S	Help/Info URL
1	CXPACKET	10644861.86	9344330.88	1300530.98	3202099312	54.22	0.0033	0.0029	0.0004	https://www.sqlskills.com/help/waits/CXPACKET
2	LATCH_EX	1653527.94	1417887.53	235640.41	962138883	8.42	0.0017	0.0015	0.0002	https://www.sqlskills.com/help/waits/LATCH_EX
3	SOS_SCHEDULER_YIELD	1627543.38	845.60	1626697.78	1856495137	8.29	0.0009	0.0000	0.0009	https://www.sqlskills.com/help/waits/SOS_SCHEDULE...
4	LCK_M_S	597828.88	597251.87	577.02	952847	3.05	0.6274	0.6268	0.0006	https://www.sqlskills.com/help/waits/LCK_M_S
5	ASYNC_NETWORK_IO	577501.34	573328.16	4173.18	123492653	2.94	0.0047	0.0046	0.0000	https://www.sqlskills.com/help/waits/ASYNC_NETWO...

Link com breve explicação sobre CXPACKET: https://www.sqlskills.com/help/waits/cxpacket/

Para chegar nessa informação, utilizei uma das queries que encontrei nas *"Googladas da Vida"*

1 - TopWaits.sql

Continuando...

Após encontrar o tipo de Waits, precisaria então verificar a quantidade de queries que estão utilizando Paralelismo para sua solução, e agrupá-las para chegar num denominador correto, e em seguida informar nos parâmetros da instancia SQL Server.

Para isso utilizei o script seguinte:

2 - Queries_With_Parallelism_x_Cost.sql

Que me trouxe a informação abaixo.

INSTANCE PRD		
StatementSubTreeCost	countInstance	Soma
1-5	1772	2341
5-6	127	
6-7	132	
7-8	120	
8-9	80	
9-10	110	
10-11	42	1227
11-12	87	
12-13	39	
13-14	22	
14-15	45	
15-16	55	
16-17	31	
17-18	31	
18-19	13	
19-20	27	
20-25	75	
25-30	75	
30-35	30	
35-40	28	
40-45	27	
45-50	16	
>50	584	

Em resumo, 2.341 Queries com custo abaixo de 10. *(já vou explicar o porquê deste corte).*

E 1.227 Queries com custo acima de 10, o que representa basicamente **34,38%** das queries. Porém, **são os 34,38% da fatia mais custosa e onerosa das queries.** Pois tem seus custos acima de 10.

E porque estou enfatizando e dividi o resultado no número "10"?!

Simplesmente porque esse é o Parâmetro que estava fixado na configuração da instancia SQL Server.

Sendo assim, é o que o SQL Server utiliza para determinar queries que serão resolvidas com Paralelismo e consequentemente CPU.

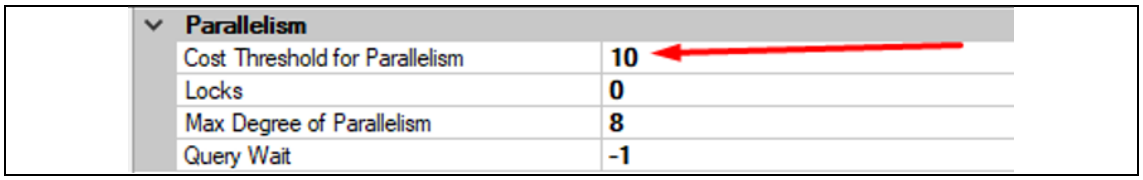

Veja que além do CTFP, temos definido também o Max Degree of Parallelism (MAXDOP). Que também deve ser levado em conta na análise, já que é o número de Core que o SQL vai utilizar para resolver as queries com Paralelismo.

Pois bem, já sabemos o WAITS e a quantidade de Query x Custo que temos, o que fazer?

Nesse caso, defini que o custo de corte seria **80**, ou seja, somente queries com CTFP acima de **80** utilizaria de recursos de Paralelismo.

Antes de mostrar o resultado, vou mostrar aqui um Plano de execução de uma query simples e seu custo, no qual estaria acima de 10 e utilizaria recursos de CPU para Paralelismo.

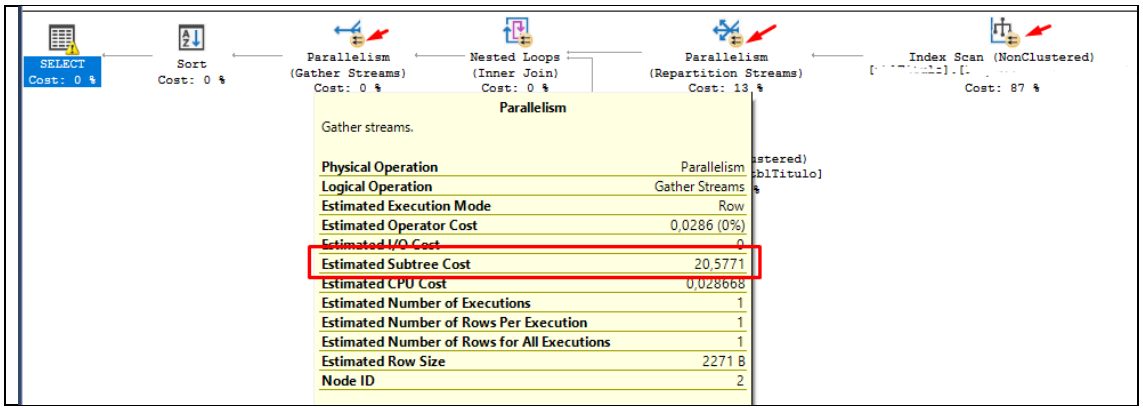

Percebam que praticamente todo o plano passa por paralelismo, e o custo é de **20,57**. O que é relativamente baixo, sendo desnecessário a utilização de CPU para a solução da Query.

"Ressalto que essa query foi demasiadamente disparada no ambiente e ocasionou um Pico de 100% de CPU, sim, essa query com custo 20." 😊

Pois bem, como já tinha a análise toda pronta, fizemos a **alteração do CTFP de 10 para 80** a quente, já que seu *COMMIT* e *ROLLBACK* são instantâneos. E reparem na descida de consumo de CPU.

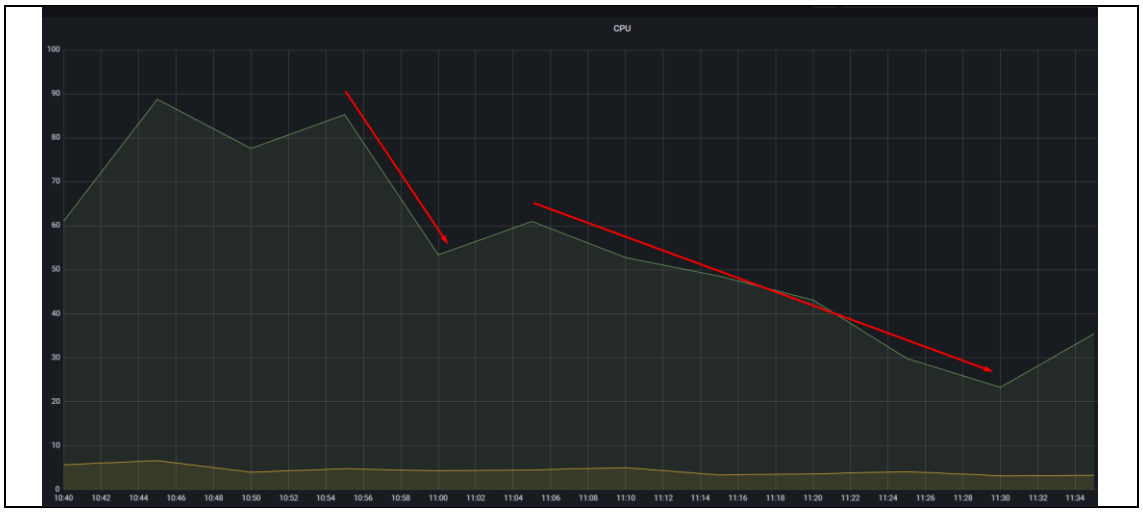

Instantaneamente tivemos uma descida de **100%** para **60%**, e descendo mais ainda até **30%** onde se manteve a média.

Gritante não é mesmo? Sim!

Com apenas um ajuste simples e sem precisar de *Restart* da Instancia ou Indisponibilidade de qualquer aplicação.

Agora vamos olhar o Plano de execução da mesma Query.

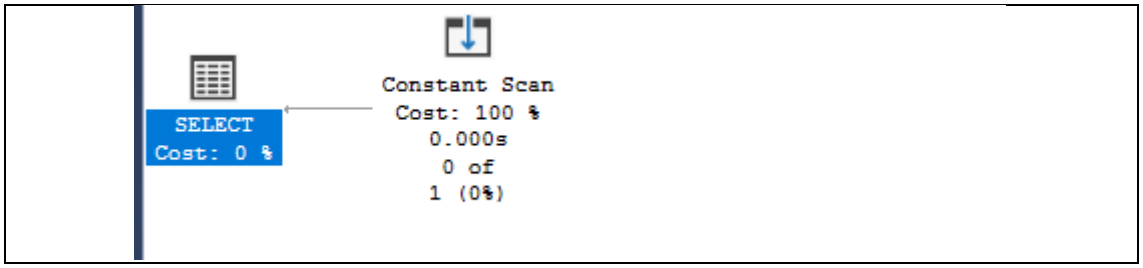

Pois é, somente um **Constant Scan** e sem utilizar paralelismo.

O que ainda não é um plano perfeito, mas com certeza nas próximas execuções esta Query será resolvida em memória, deixando a query ainda mais rápida.

Para essa alteração surgem algumas dúvidas, que acho interessante pontuar aqui, são elas:

- A aplicação pode ficar mais lenta, já que não está utilizando CPU (recursos robustos do servidor) para resolver as queries?

- Não! O SQL funciona justamente ao contrário, se a query já está em memória, não precisa resolver novamente, pois já tem seu Plano de execução (Hash) pronto para reutilizá-lo.

- Se em memória são melhores, não devemos aumentar o parâmetro para não resolver queries com CPU?

- Não! Precisamos da CPU justamente para resolver soluções aritméticas e queries extremamente custosas que não ficam no buffer de memória. Por exemplo aquelas que contêm CONVERT IMPLICIT (comparação de datatypes diferentes na query).

- Essa alteração é vitalícia?

- Não! É interessante que seja monitorado e ocorrendo desvios rotineiros de CPU, seja feita uma nova análise das queries e seus custos para definir um novo parâmetro.

- Não vai mais ocorrer picos de CPU?

- Podem ocorrer picos de CPU sim, se no ambiente existem outras operações que podem apresentar alto consumo de CPU. (por exemplo: Replication, Convert Implicit). Porém, os desvios serão menores, ocorrerão com menos frequência e será mais fácil de apontar um possível responsável pelo desvio.

Por fim, apesar da rápida implementação e ter um impacto extremamente positivo. Essa é uma alteração que requer a análise de um DBA Sênior Especialista.

Por fim, espero ajudar com essa Análise.

Junior Moraes
DBA SQL Server Senior Consultant
Cel: +55 (41) 9 88816464
e-mail: jcjunior.dba@outlook.com